

Тема

Итоговая работа по курсу Big Data

- NoSQL и Big Data хранилища для векторного поиска
- Практика: semantic search по Airbnb listings
- Сравнение: pgvector, Qdrant, Milvus

103k

Airbnb listings после очистки

384d

embeddings all-MiniLM-L6-v2

HNSW

индекс для ANN search

Зачем нужен векторный поиск

Классический поиск хорошо работает по точным словам и фильтрам

- Semantic search ищет объекты, близкие по смыслу
- Текст объявления превращается в embedding-вектор
- База ищет ближайшие векторы по cosine similarity
- Подход используется в рекомендациях, RAG и поиске по документам

103k

Airbnb listings после очистки

384d

embeddings all-MiniLM-L6-v2

HNSW

индекс для ANN search

Pipeline эксперимента

Raw data: CSV-файлы InsideAirbnb

- Preprocess: очистка цены, координат, описаний
- Text field: name + description + city + rooms + price
- Embeddings: all-MiniLM-L6-v2, 384 dimensions
- Indexing: загрузка в pgvector, Qdrant и Milvus
- Serving: Flask dashboard с поиском и картой

103k

Airbnb listings после очистки

384d

embeddings all-MiniLM-L6-v2

HNSW

индекс для ANN search

Архитектура стенда

Компонент	Роль
runner	ETL, embeddings, indexing, benchmark
PostgreSQL + pgvector	SQL-хранилище с vector extension
Qdrant	Отдельная vector database
Milvus + etcd + MinIO	Vector DB для масштабируемого сценария
visualization	Flask UI: поиск, карта, benchmark

103k

Airbnb listings после очистки

384d

embeddings all-MiniLM-L6-v2

HNSW

индекс для ANN search

Чем отличаются системы

Система	Тип	Когда выбирать
pgvector	PostgreSQL extension	MVP, SQL, простая интеграция
Qdrant	Vector-first DB	Отдельный semantic search service
Milvus	Scalable vector DB	Большие коллекции и высокая нагрузка

103k

Airbnb listings после очистки

384d

embeddings all-MiniLM-L6-v2

HNSW

индекс для ANN search

Данные и модель

Источник: InsideAirbnb listings

- После очистки: 103 171 объявление
- Поля: name, description, city, price, bedrooms, bathrooms, lat/lon
- Embedding model: sentence-transformers/all-MiniLM-L6-v2
- Размерность вектора: 384
- Индекс: HNSW во всех трех системах

103k

Airbnb listings после очистки

384d

embeddings all-MiniLM-L6-v2

HNSW

индекс для ANN search

Скорость индексации

Система	Время	Примерная скорость
pgvector	1442.8 s	72 rec/s
Qdrant	165.7 s	623 rec/s
Milvus	57.0 s	1809 rec/s

103k

Airbnb listings после очистки

384d

embeddings all-MiniLM-L6-v2

HNSW

индекс для ANN search

Latency и recall

Система	P50	P95	P99	Recall@10
pgvector	16.65 ms	27.15 ms	38.16 ms	1.000
Qdrant	59.69 ms	84.85 ms	88.30 ms	0.889
Milvus	11.37 ms	18.61 ms	48.48 ms	0.909

103k

Airbnb listings после очистки

384d

embeddings all-MiniLM-L6-v2

HNSW

индекс для ANN search

Что показал поиск в UI

Пользователь вводит текстовый запрос

- Запрос кодируется той же embedding-моделью
- Можно выбрать одну или несколько баз
- Top-K настраивается на фронте
- Карточки показывают описание, параметры, координаты и ссылку на listing

103k

Airbnb listings после очистки

384d

embeddings all-MiniLM-L6-v2

HNSW

индекс для ANN search

Облачные и российские варианты

AWS: OpenSearch vector search

- Google Cloud: Vertex AI Vector Search
- Azure: Azure AI Search
- Managed vector DB: Pinecone, Zilliz Cloud, Qdrant Cloud
- Российский контекст: self-hosted pgvector/Qdrant/Milvus, Managed OpenSearch,
- Kubernetes или VM у локального провайдера

103k

Airbnb listings после очистки

384d

embeddings all-MiniLM-L6-v2

HNSW

индекс для ANN search

Выводы

pgvector: лучший старт, если приложение уже использует PostgreSQL

- Qdrant: хороший выбор для отдельного semantic search API
- Milvus: сильный вариант для больших объемов и масштабирования
- Выбор зависит не только от latency, но и от эксплуатации
- Важны обновления индекса, фильтры, стоимость RAM и требования к данным

103k

Airbnb listings после очистки

384d

embeddings all-MiniLM-L6-v2

HNSW

индекс для ANN search

Что улучшить дальше

Exact ground truth через brute force или FAISS

- Concurrent benchmark для 5/10/50 пользователей
- Измерение RAM и disk usage
- Подбор HNSW параметров M, ef_construction, ef_search
- Фильтры по городу, цене и числу комнат
- Hybrid search: keyword + vector + reranking

103k

Airbnb listings после очистки

384d

embeddings all-MiniLM-L6-v2

HNSW

индекс для ANN search